Proyecto 1, Entrega 3 - Arquitectura, conclusiones y consideraciones

Integrantes:

- Daniel Santamaría Álvarez 201720222
- Nestor Gonzalez 201912670
- Álvaro Plata 201820098
- Rafael Humberto Rodriguez Rodriguez 202214371

Para poder incorporar los cambios de la infraestructura, primero incorporamos el SDK de google cloud, específicamente el módulo de almacenamiento.

```
from google.cloud import storage
```

Después, se debe obtener el cliente, que corresponde a la cuenta de servicio de la maquina virtual, para obtener acceso al API de los buckets de storage. Para poder acceder al bucket se debe usar su nombre único definido en la creación.

```
storage_client = storage.Client()
bucket = storage_client.bucket(bucket_name)
```

Con la conexión al bucket, se deben usar blobs que obtienen y almacenan los archivos de audio en su correspondiente bucket. Por ejemplo, en la estructura definida para el almacenamiento del proyecto, habrá una carpeta por conversión con el id asignado a la tarea y en su interior contiene el archivo original y el modificado. Para cargar el archivo se usa la función upload_from_file del blob.

```
in_route = "{}/{}".format(task.id,filename)
out_route = "{}/{}".format(task.id,filename.replace(f'.{in_ext.lower()}',f'.{out_ext.lower()}'))
blob = bucket.blob("{}/{}".format(task.id, filename))
blob.upload_from_file(original_audio)
```

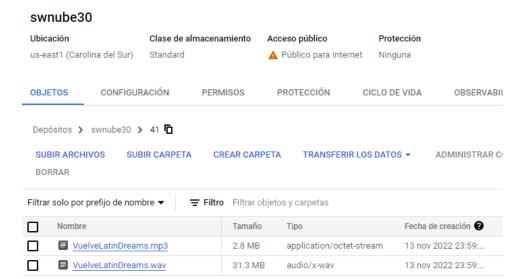
Igualmente, en el procesamiento asíncrono, se obtiene el archivo original mediante la variable in_route como ruta del blob y se descarga el archivo a una ruta local. A partir de este archivo, se hace la conversión y en un blob con la ruta de destino se carga el nuevo archivo.

```
blob = bucket.blob(in_route)
blob.download_to_filename("{}".format(in_route.split("/")[1]))
AudioSegment.from_file("{}".format(in_route.split("/")[1],format=in_ext)).export("{}".format(out_route.split("/")[1]), format=out_ext)
blob = bucket.blob(out_route)
blob.upload_from_filename(out_route.split("/")[1])
```

Para poder controlar la petición que realiza el procesamiento asíncrono al finalizar una tarea, se definió la variable de entorno API_INSTANCE_IP que apunta a la dirección del balanceador de carga para que redirija la petición a un servidor web disponible.

```
r = requests.post(f'http://{os.environ.get("API_INSTANCE_IP")}:5000/api/tasks/{task_id}/processed')
```

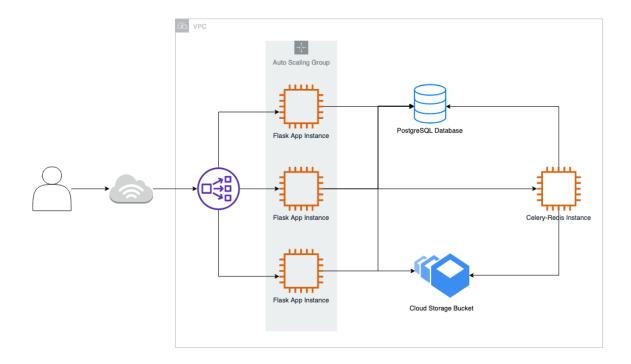
De acuerdo con los cambios anteriores, se puede ver el bucket con la estructura definida:



Para poder crear instancias con escalamiento automático, se definió un script que se ejecuta siempre que se crea una instancia para instalar las dependencias y el código que se despliega:

```
#! /bin/bash
sudo apt-get update
sudo apt-get install python3
sudo apt-get install python3-pip -y
sudo apt-get install git -y
sudo apt-get install ffmpeg -y
sudo pip3 install virtualenv
git clone https://github.com/NestorGon/SWNube.git
cd SWNube
virtualenv venv
source bin/activate
pip3 install -r requirements.txt
cd flaskr
export REDIS_INSTANCE_IP=35.238.0.106
python3 -m flask run --host=0.0.00
```

Descripción de la arquitectura desplegada en Google Cloud



A continuación, se describen los principales cambios realizados a la arquitectura de la aplicación desde la última entrega:

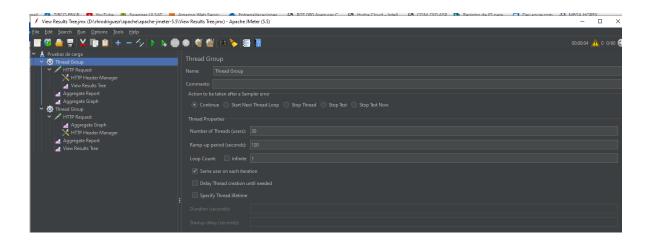
- Sustitución del servidor de NFS por el uso de un servicio administrado de almacenamiento de Objetos, Google Cloud Storage, para el almacenamiento de los archivos de audio originales y compartidos.
- Creación de una Plantilla de Instancias y un Grupo de Instancias de auto escalamiento. Estos elementos reemplazaron a la instancia única que anteriormente se encontraba sirviendo la aplicación de Flask (capa web). De esta forma, ahora la capa web puede escalar y desescalar automáticamente dependiendo del tráfico que reciba la aplicación.
- Creación de un Blanaceador de Carga, que distribuye la carga y apunta hacia el grupo de instancias que se crean y eliminan de manera dinámica, de manera que las peticiones que vienen directamente de los usuarios ahora apuntan al balanceador en lugar de una instancia específica.

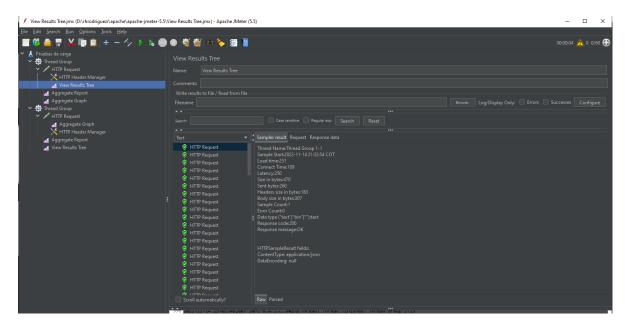
Análisis de Capacidad.

Pruebas de estrés sobre el Modelo de Despliegue

Escenario 1

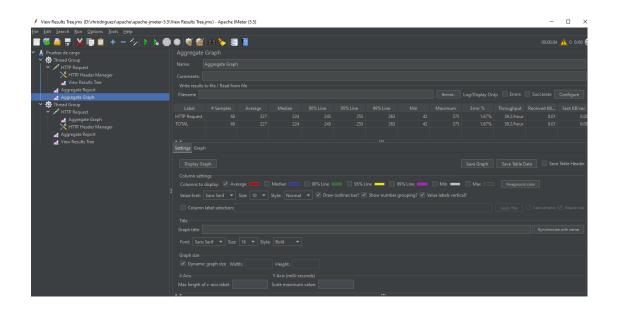
Login

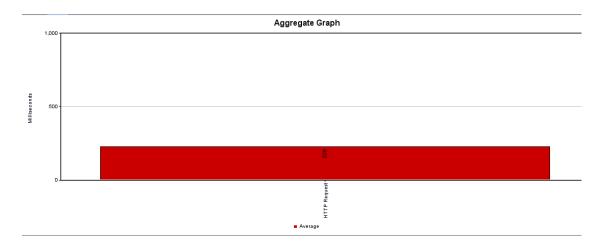




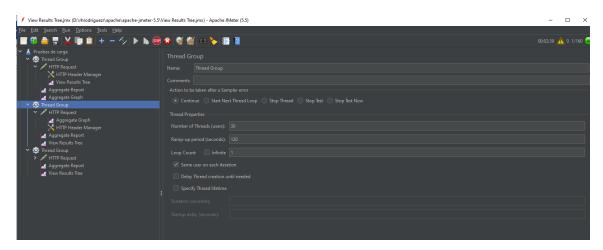
El porcentaje de error supera el 1 % por lo cual se puede deducir que la prueba es fallida.



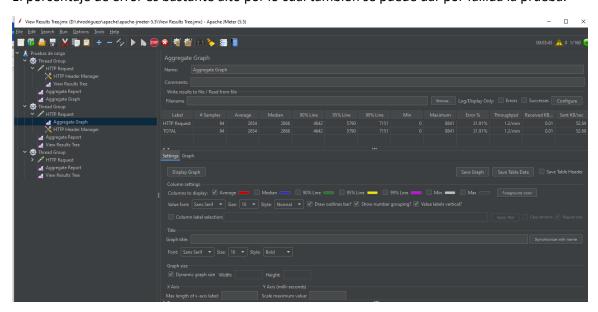




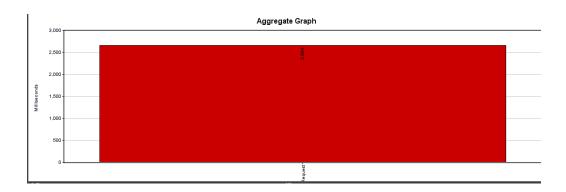
Conversión de archivos.



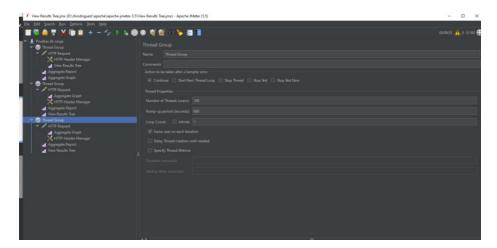
El porcentaje de error es bastante alto por lo cual también se puede dar por fallida la prueba.



Se supera el tope propuesto del escenario de 1.5 ms por petición



Escenario 2



El porcentaje de conversiones por minuto es de 10 archivos.

